Tách bảng tài chính và lập chỉ mục cho RAG

Dò bảng không viền → phân đoạn → truy xuất lai

Toàn bộ nội dung mô tả mã đang chạy trong `etflab/`, không phải thiết kế đề xuất. Kết quả đo thật trên corpus của đồ án được ghi ở `docs/Tham_Khao_va_nguon.md`, mục 5.5.

Đặt vấn đề: bảng tài chính trong PDF của công ty chứng khoán

Dạng dữ liệu

- Bảng tỷ trọng, danh mục, thay đổi thành phần chỉ số.
- Bố cục dạng cột, **không có đường viền**.
- Chỉ có một lớp ký tự có tọa độ, không có nét vẽ.

Hai điểm khó

- Về **bố cục**: biên cột phải suy ra từ khoảng trống ngang.
- Về **lớp ký tự**: 307/340 trang là bản scan, không đọc được gì.

Hệ quả

Không có công cụ “bấm vào vùng bảng” như khi làm Excel. Mọi thứ phải dựng lại từ hộp toạ độ của từng từ.

Vì sao không dùng `pymupdf.find_tables()`

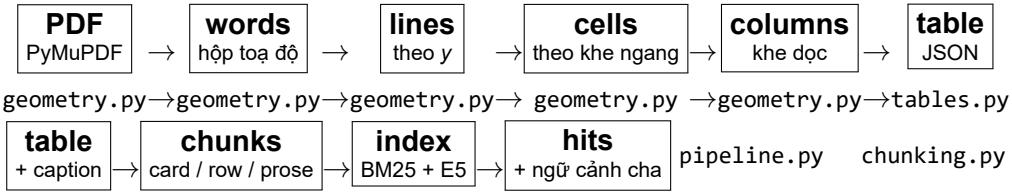
- `find_tables()` dò theo **đường vẽ** (vector line) rồi dựng lưới ô.
- Báo cáo của công ty chứng khoán Việt Nam *không vẽ bảng*: chỉ có chữ, các cột ngăn cách bằng khoảng trắng.
- Nhận xét này được ghi thẳng trong docstring của module hình học:

> *"`pymupdf.find_tables()` chỉ làm việc với bảng có đường viền. Báo cáo của CTCK Việt Nam dùng bảng không viền — chỉ được bảo vệ bảng bằng cách sắp xếp theo trục x. Từ đó khôi phục trực tiếp từ toạ độ từ."* — `etflab/geometry.py`

Hướng giải quyết

Khôi phục lưới tọa độ (dòng $\rightarrow$ ô $\rightarrow$ cột) từ hộp bao của các từ, rồi áp ngưỡng để quyết định vùng nào *là* bảng.

Kiến trúc tổng thể



Tầng 1: từ ký tự đến ô

`words_from_page` Đọc `page.get_text("words")` $\rightarrow$ `Word(x0,y0,x1,y1,text)`, sắp xếp theo (c_y, x_0).

`median_char_width` Trung vị của $(x_1 - x_0)$/len trên từ dài ≥ 3 ký tự. **Mọi ngưỡng sau đều bằng bội số của số này**, nên không phụ thuộc cỡ chữ.

`build_lines(y_tol=3.0)` Hai từ cùng dòng nếu $|c_y - c'_y| \leq 3$pt.

`group_cells` Tách ô khi khe ngang $> \max(4.0,\ 1.6\, c_w)$.

Vì sao đo bằng ký tự

Báo cáo tiếng Việt trộn cỡ chữ (chú thích nhỏ hơn số liệu). Ngưỡng tính theo *số ký tự* tự co theo cỡ chữ thay vì phải cấu hình riêng cho từng font.

Bước quyết định

Mỗi ô vừa tách xong được `parse_number()` ngay. Ô nào đọc được như số thì mang thông tin *nhịp số* — đây là manh mối mọi bước sau.

Tầng 2: biên cột bằng khe trống dọc chung

Ý tưởng: cột là khoảng trống *dọc* không bị từ nào phủ

Một cột đúng thì **mọi dòng dữ liệu** đều hở ra ở cùng một đoạn x.

1. Rải toàn bộ từ của vùng lên trục x với ô lưới 1pt.
2. Đếm số dòng phủ từng ô lưới; ô nào $\leq$ `allow_sparse` coi là trống.
3. Các đoạn trống liên tiếp dài $\geq \max(7.0,\ 2.0\,c_w)$ là biên cột.
4. `tighten_columns` thu biên về phân bố thật ± 1pt.

Gán ô vào cột

`assign_to_columns`: chọn cột có độ phủ lớn nhất; bỏ ô nếu phủ $< 30\%$ bề rộng ô; gộp nhiều ô rơi cùng cột.

`allow_sparse = 1`

Cho phép một cột trống ở một dòng. Nếu phải đủ mọi dòng, những dòng có ô rỗng (cột rộng) sẽ làm nát lưới cột.

Tầng 3: dò vùng bảng

Điều kiện bắt buộc phải có số

Một dòng được đánh dấu là “dòng bảng” khi thỏa **cả hai**:

$$\text{số ô đọc được như số} \;\geq\; 3 \qquad \textbf{và} \qquad \frac{\text{số ô số}}{\text{số từ trên dòng}} \;\geq\; 0.25$$

- Các dòng đánh dấu liên tiếp ≥ 4 tạo thành một *vùng ứng viên*.
- Rồi vùng đó phải qua kiểm tra lưới ở slide kế tiếp mới được giữ.

Tham số (`TableConfig`)	**Ý nghĩa**
`min_numeric_cells = 3`	dòng phải có tối thiểu 3 ô số
`min_numeric_density = 0.25`	tỉ lệ ô số trên dòng
`min_run_rows = 4`	số dòng liên tiếp tối thiểu
`max_cols_single_table = 8`	quá ngưỡng này thì nghi là *bảng kép*
`min_row_alignment = 0.60`	tỉ lệ số cột phủ tối thiểu trên một dòng

Loại văn xuôi căn đều: `_grid_is_stable()`

Vì sao cần bước này

Văn xuôi căn đều (*justify*) có nhiều con số rải rác: “tăng 12% so với đầu năm”, “từ 1.234 đồng”. Ba ô số vẫn đạt. Chỉ nhịp số chưa đủ.

1. Lưới cột phải có ≥ 3 cột.
2. Gọi một dòng là *đúng lưới* khi: có ≥ 2 ô số **và** các ô phủ $\geq 60\%$ số cột.
3. Tổng số dòng đúng lưới phải $\geq \max(4,\ 0.7 \times$ số dòng vùng$)$.

`_grow_run()` — nới vùng

Nhiều dòng hợp lệ có *cột rỗng* nên không đủ 3 ô số, vùng bị cắt làm mất dữ liệu ngầm. Ta nới tối đa 2 vòng, chỉ nhận dòng khi dòng đó *vẫn còn* ô số và vẫn phủ lưới cột — nên không lan sang header hay văn xuôi.

Cột rỗng không phá vỡ tiêu chí

Tiêu chí là số ô *phủ một cột đã xác định*, không phải số ô thực tế. Vì vậy dòng thiếu ô ở cột rộng vẫn là dòng dữ liệu hợp lệ.

Tách khối tiêu đề: `_header_block()`

Cách làm

Từ dòng đầu tiên của vùng dữ liệu, đi *lên* tối đa `max_header_lines = 6` dòng.

Bốn điều kiện dừng

1. dòng đã có ≥ 2 ô số $\rightarrow$ đã vào dữ liệu;
2. khớp mẫu caption ``` ``Bảng 3: ...'' ```;
3. khớp mẫu header chạy (URL, “Trang 12”, DOI);
4. là *câu văn* sót lại.

Vì sao cần điều kiện 4

Dòng chú thích kiểu “22/04/2026.” nằm giữa caption và header thật. Nó có đúng *một* ô và dấu hiệu đầu dòng lệch sang trái khỏi mép trái cột dữ liệu. Nếu giữ lại, nó bị gán cho *mọi* cột và tên cột biến thành “22/04/2026. STT”.

Chỉ cần một ô lẻ

Dòng nhiều ô thì dùng cấu trúc bảng để quyết định — không cần.

Header nhiều tầng và tên cột

- `_header_levels()` ghi **từng tầng header** $\times$ **từng cột**.
- Ô header được nhận nếu $\max\left(\frac{\text{phủ ô}}{\text{rộng cột}}, \frac{\text{phủ ô}}{\text{rộng chính ô}}\right) \geq 0.25$. Tỉ lệ thứ hai ổn định hơn vì bề rộng cột biến thiên giữa các trang.
- Ô **loại** nếu trải ≥ 3 cột và chiếm quá nửa tổng số cột — đó là chú thích đặt ngang, không phải tên cột.

Khoá tầng vào cột	Kết quả
`_column_names()`	gom ô theo `_match_column()`: phủ $\geq 40\%$ bề rộng cột, nếu không thì lấy tâm gần nhất trong bán khoảng
`_names_from_levels()`	nối các tầng bằng dấu `/`, bỏ tầng rỗng và tầng lặp lại

Header nhiều tầng “Số lượng CP mua/bán” trải trên cột đầu và cột sau: giải pháp là *cho phép một ô xuất hiện ở nhiều cột*.

Tách hai bảng đặt cạnh nhau

- Nếu bảng dựng được có $n_{\text{cols}} \leq 8 \rightarrow$ coi là một bảng.
- Vượt ngưỡng $\rightarrow$ nghi là **hai bảng đặt cạnh nhau**, thử cắt đôi.

`_split_slab()` — nguyên tắc "cả hai bên đều phải là bảng"

1. Tìm khe dọc rộng (rộng hơn `min_split_band`, mặc định $\max(14,\ 4c_w)$).
2. Dựng thử bảng bên trái và bên phải.
3. **Chỉ cắt** khi cả hai đều hợp lý; nếu không thì thử khe kế tiếp.
4. Lặp tối đa 2 tầng.

Ưu tiên khe gần giữa

Hai bảng cạnh nhau thường được *căn giữa* trang, nên khe ở gần giữa vùng là ứng viên đúng nhất. Khe giữa hai cột của *cùng một* bảng cũng thỏa điều kiện "hai bên đều là bảng" — chọn sai sẽ cắt nhầm một bảng thành hai.

`_is_plausible()`

≥ 4 dòng, ≥ 2 cột, ≥ 2 cột chứa số.

Khi hai bảng không hề có khe: tiêu đề nhóm

Tình huống thật — bản tin Q1/2026

Hai bảng đặt cạnh nhau nhưng khe giữa chỉ **12pt**, nhỏ hơn khe giữa hai cột của *cùng* bảng (16–70pt). Dò tìm khe không ra gì.

Nhưng header lại có dấu hiệu mạnh hơn

Một dòng “Kich bản 1: ... | Kich bản 2: ...” — mỗi ô là tên của một bảng. Đây là bằng chứng *cấu trúc*, không phụ thuộc bề rộng khe.

`_group_title_bands()` chỉ nhận dòng khi thỏa đồng thời

- ≥ 6 tâm ô dữ liệu khác nhau (ít hơn thì chưa đủ tin cậy)
- mỗi ô là chuỗi dài ≥ 12 ký tự, và các nhãn *khác nhau*
- mỗi ô phủ ≥ 2 cột; mỗi nhóm còn ≥ 3 cột; khe rộng $\geq 3c_w$

Dòng tiêu đề nhóm được *giữ trong header* (để đối chiếu khi gộp bảng qua trang) nhưng bị đánh dấu để không dùng làm tên cột.

Chuẩn hoá số và đơn vị kiểu Việt Nam

parse_number()

- Dấu chấm là phân cách nghìn, dấu phẩy là thập phân: `2.976,9` $\rightarrow 2976.9$.
- Phân biệt ngày `22/04/2026` với số.
- Gắn cờ `is_percent` cho số có `%`.

Đơn vị unit_notes

Quét tên cột theo mẫu `(nghìn|ngàn|tr|tỷ|triệu) (cổ phiếu|cp|đồng|usd|vnd)` cộng với cờ `percent`.

Nhận diện cột STT và cột mã chứng khoán

- `_is_row_index()`: số nguyên tăng đúng 1, ít nhất 4 giá trị $\Rightarrow$ cột số thứ tự, *không phải* cột đo lường.
- `TickerExtractor`: `^A-ZĐ{2,6}$`, dài ≤ 6, không phải số; $\geq \max(2,\ 60\%)$ dòng khớp thì là cột `ticker`.

numeric_cols

Cột được tính là cột số nếu $\geq 40\%$ số dòng đọc được như số. Đây là đầu vào cho `_is_plausible()` và cho việc loại cột STT khỏi phần rút gọn.

Hậu xử lý ở tầng tài liệu

Hàm (`pipeline.py`)	Nhiệm vụ
`_find_caption()`	gom tối đa 4 dòng phía trên vùng bảng; dừng ở mục mới, caption mới, hoặc dấu kết câu
`_prose_blocks()`	phần văn xuôi: loại vùng bảng, chân trang ($y > 0.94H$) và mẫu footer
`_merge_continuations()`	gộp bảng bị cắt giữa 2 trang
`_assign_ids()`	đánh số `{tên_file}__t01`

Gộp bảng xuyên trang

Khớp *chữ ký* = tên cột đã bỏ dấu, cần ≥ 2 cột khác rỗng; phải trùng vùng x; bỏ qua hai bảng cùng trang cách nhau ≥ 120pt. Khi khớp: nối dòng, hợp `page_span`, nới vùng y và x.

Cảnh báo thiếu lớp ký tự

Đếm trang không có từ nào. Nếu *tất cả* trang đều rỗng, cảnh báo rõ: PDF đang scan, cần OCR trước khi nạp. Nếu chỉ một phần, liệt kê tối đa 10 trang đầu.

Bài toán lập chỉ mục: chia chunk thế nào

Ba loại chunk

- `table_card` — 1 chunk/bảng: tên cột + nhãn dòng.
- `table_row` — 1 chunk/dòng dữ liệu, `parent_id = table_id`.
- `prose` — văn xuôi, đã loại footer.

Ô rỗng được giữ lại

Ô trống ghi `missing: true` thay vì bị xoá — nếu xoá, không phân biệt được "không có dữ liệu" với "cột này không áp dụng".

Hai bản văn cho mỗi chunk

- `text` — đầy đủ, dạng "Tỷ trọng: 12,4% | ...", cho vector.
- `sparse_text` — rút gọn: nhãn dòng + các cột số, cho BM25.

Cột định danh không lấy theo vị trí

Nhiều bảng không có cột STT mà bắt đầu bằng "Ma CK" rồi tới cột số. Nếu cắm số thứ tự, cột "Ma CK" rơi vào phần *rút gọn* và giá trị mất khỏi chỉ mục BM25. Chỉ cột *chữ* mới là nhãn dòng.

Token hoá tiếng Việt cho BM25

- Bỏ dấu, đưa đ → d, hạ chữ thường.
- **Không** bỏ từ "trong" khỏi danh sách dừng — cột quan trọng nhất của báo cáo Việt Nam là "Tỷ *trọng*".

Số: lập chỉ mục cả hai cách hiểu

Người dùng hỏi "2976.9", tài liệu ghi "2.976,9". Thay vì phải chọn, ta **index cả hai**:

- thử cả "chấm = nghìn" lẫn "chấm = thập phân" → sinh token số chuẩn hoá;
- thêm `phan_tram` nếu là phần trăm;
- thêm các thành phần tách theo `[.,]` để hỏi theo cách viết khác cũng trúng.

Đơn vị ngữ nghĩa của BM25

Người hỏi theo **mã chứng khoán** và **con số** — BM25 khơn chính xác các token này, vector search thường bỏ qua. Ngược lại, câu hỏi kiểu "quy mô đầu tư tăng mạnh" thì BM25 không hiểu, vector search hiểu.

Metadata là ràng buộc, không phải từ khoá

Nhận dạng tài liệu (`docmeta.py`)

Từ tên file (“Thay_doi_thanh_phan_chi_so_VN30_Q2_2026.pdf“), không có kỳ thì lấy từ trang đầu: loại tài liệu, chỉ số, kỳ, năm, ngày. Nhãn dạng “Bản tin thay đổi thành phần chỉ số VN30 kỳ Q2/2026” được **tiền tố** cho mọi `sparse_text`.

`DocFilter` — lọc cứng

Nhận diện từ câu hỏi: `Q1`–`Q4`, “quý II”, `VN30`/`VN-DIAMOND`/`VN-FIN-LEAD`, “dự báo”/“điều lệ”, năm 4 số. Chunk không khớp bị loại **trước khi tính điểm**.

Vì sao không giao cho BM25 tự xử lý

BM25 *cộng* điểm. Với 223 chunk chứa `q2` (idf 1.2) và 12 chunk chứa `bsr` (idf 4.1), câu “tỷ trọng mới của BSR Q2” vẫn trả về bản Q3. `q2` là *điều kiện*, không phải *điểm cộng*.

Truy xuất lai: BM25 + vector + RRF

Nhánh thưa

Okapi BM25, $k_1 = 1.5$, $b = 0.75$:

$$\mathrm{idf} = \ln\left(1 + \frac{N - df + 0.5}{df + 0.5}\right)$$

Không cần ANN, không cần thư viện ngoài.

Ghép bằng RRF

$$\mathrm{RRF} = \sum \frac{w}{k + \mathrm{rank}}, \quad k = 60$$

Chỉ cần *thứ hạng*, không cần chuẩn hoá thang điểm hai bên — đây là lý do RRF hợp hơn cộng điểm thô.

Nhánh dày

`multilingual-e5-small`, vector chuẩn hoá, so khớp cosin. Bắt buộc tiền tố `` `query: ' `` và `` `passage: ' `` — thiếu làm khoảng cách đầu vào và đầu ra lệch nhau.

Mặc định tắt nhánh dày

`use_dense = False`: bật sẽ tải mô hình 500MB ngay lần chạy đầu. Nếu thiếu `sentence_transformers` hoặc lỗi tải, hệ thống **tự ghi cảnh báo và chạy tiếp bằng BM25** thay vì sập.

Đọc kết quả: mở rộng ngữ cảnh cha

- Chunk cha (`table_card`) được lưu theo *khoá* `table_id`, không phải `chunk_id`: chunk dòng có `parent_id = table_id`, còn chunk cha có khoá dạng `...#card`.
- Khi trả hit dòng, `parent_text` cắt ở `parent_max_chars = 420`.

Cách đọc hit

`Hit` mang cả `bm25_rank`, `dense_rank` và `score` RRF — nhìn thấy *vì sao* chunk đó lọt vào top-k, không chỉ biết nó có trong kết quả.

Phạm vi

Đây là cơ chế *cha–con*, cùng hướng với bài báo dual-granularity đã trình bày riêng. Hiện chưa có bộ câu hỏi vàng để chứng minh cơ chế này tăng độ chính xác so với chia chunk theo phần tử.

Đo thật trên corpus của đồ án

Cách đo

12 PDF / 340 trang (33 trang có lớp ký tự, 307 trang scan). So sánh quy tắc của đồ án với Table Transformer (TATR) — hai checkpoint công khai. Mã đo nằm ngoài kho mã nguồn, không đụng vào hệ thống.

	Quy tắc (`tables.py`)	**Table Transformer**
33 trang có lớp ký tự	**18** bảng	43 bảng
307 trang scan	0 (không có lớp ký tự để dò)	343 bảng
Trên 33 trang có lớp ký tự (có ground truth):		
Cả hai cùng thấy (TP)		13
Chỉ TATR thấy (FP)		**13**
Chỉ quy tắc thấy (FN)		1
Precision / Recall		**50% / 93%**

Cấu trúc: khớp 11/15 cột, số dòng thì không

So sánh cấu trúc trên 15/18 bảng đo được

3 bảng bị bỏ vì ghép qua trang, không lấy được nhãn.

Kiểm tra	Kết quả
Số cột khớp	**11/15 (73%)**
Số dòng	**không đáng tin** — lệch từ ± 1 đến $+12$

Bốn ca lệch số cột đều rơi vào lỗi đã biết trước

- $18\times5 \rightarrow$ TATR 18×4 và $46\times8 \rightarrow$ TATR 61×6: **hai bảng cạnh nhau bị tách nhầm**.
- $18\times8 \rightarrow 18\times9$ và $32\times7 \rightarrow 32\times6$: chênh lệch ở biên cột đầu/cuối.

Điểm mù của hai bên

Quy tắc thua ở đâu

Bảng **văn bản thuần, ít cột, ít số**. Ví dụ phụ lục “Tiêu chí đánh giá chỉ số VN DIAMOND INDEX 3.0” (`Q4_2024` trang 5, điểm 0.953): đòi ≥ 3 ô số nên bị `_find_regions()` loại. Trang 2 cùng tệp cũng có thể là danh sách quỹ.

TATR thua ở đâu

Trang *miễn trừ trách nhiệm* và khối thông tin liên hệ bị nhận là bảng với điểm tới **1.0** — gần như toàn bộ 13 trang FP thuộc nhóm này. Ngược lại một trang có **2 bảng thật** thì TATR phát hiện **0**. Cả hai hệ đều không có khái niệm bảng xuyên trang.

Kết luận: kiến trúc lai, không thay thế

Quy tắc làm **neo độ chính xác**; mô hình **bổ sung độ bao phủ** cho lớp bảng mà quy tắc cố ý loại. Mọi đề xuất của TATR phải đi qua bộ lọc trước khi được nhận. Bằng chứng không cho phép kết luận “quy tắc thắng mô hình”.

Bộ lọc khe lặp: một phép đo thay cho ground truth

Vì sao cần

307 trang scan không có ground truth. Nhưng một bảng — kể cả không viền — luôn thể hiện *cùng các khe cột nội bộ* trên nhiều dòng; văn xuôi thì méo.

Nhóm	n trang	khe lặp (median)	≥ 2 khe lặp
POS — trang có bảng, quy tắc xác nhận	15	**8.0**	**100%**
NEG — trang văn xuôi, quy tắc loại	28	1.0	29%
SCAN — 307 trang scan	40	**1.0**	38%

- Nhóm SCAN thống kê *giống nhóm báo động giả*, xa nhóm bảng thật $\Rightarrow$ phần lớn 343 phát hiện trên trang scan là văn xuôi bị nhận nhầm, dù điểm tin cậy rất cao (0.83–0.999).
- Bộ lọc loại **62%** của NEG trong khi giữ **100%** của POS $\Rightarrow$ dùng được làm bộ kiểm lọc đề xuất của TATR.

Giới hạn đã biết

Giới hạn về đo lường

- Chưa có ground truth độc lập cho 307 trang scan.
- Chưa đo TEDS — mới chỉ so số cột.
- Số dòng TATR trả về lệch tới $+12$, chưa dùng được.
- Chưa có bộ câu hỏi vàng để đo `Recall@k`, MRR hay chất lượng sinh.

Giới hạn về phạm vi

- Chỉ chạy trên PDF có lớp ký tự; trang scan cần OCR trước.
- Không xử lý bảng xoay.
- Cần biết kích thước số lượng phần trăm, cột không đều nhau, ô gộp dọc.
- Nhánh dày mặc định tắt, chưa so sánh BM25 thuần với lai trên câu vàng.

Cách đọc đúng các con số đã trình bày

Chúng là kết quả đo trên *đúng corpus của đồ án*, không phải điểm chuẩn công bố. Vì vậy dùng để so sánh *giữa hai hệ trong cùng điều kiện*, không dùng để so với số liệu đào tạo của TATR.

Bản đồ mã nguồn

Module	Trách nhiệm
`vnnum.py`	chuẩn hoá số kiểu Việt Nam, bỏ dấu, gỡ hiểu ngày
`geometry.py`	dòng, ô, biên cột, gán ô vào cột
`tables.py`	dò vùng bảng, tách bảng kép, dựng tên cột, đơn vị, cột mã
`pipeline.py`	đọc PDF, caption, gộp bảng qua trang, đánh số, cảnh báo
`docmeta.py`	nhận dạng loại tài liệu, chỉ số, kỳ, năm
`chunking.py`	`table_card` / `table_row` / `prose`
`retrieval.py`	token hoá, `BM25`, dense, `RRF`, `DocFilter`
`cli.py`	nạp tài liệu và tra cứu

Tài liệu chi tiết theo từng hàm:

`docs/Huong_dan_ky_thuat.md`

Thí nghiệm và nguồn trích dẫn: `docs/Tham_Khao_va_nguon.md`

Kết luận

1. Bảng tài chính không viền được nhận diện bằng **nhịp số** và **khe dọc lặp lại**, không dựa vào đường vẽ nào.
2. Ba tầng quyết định chất lượng: *dòng có số* → *lưới cột ổn định* → *đúng là bảng*.
3. Tách bảng kép cần hai loại bằng chứng: khe dọc rộng, và tiêu đề nhóm trong header khi khe không đủ rõ.
4. Chunk tách theo **dòng dữ liệu** và **giữ nguyên ô rỗng**; nhãn dòng lấy từ cột chữ, không phải cột đầu.
5. Chỉ mục là **hybrid**: BM25 cho mã và con số, vector cho ý nghĩa, RRF để ghép; metadata dùng để *lọc*, không dùng để cộng điểm.
6. Bằng chứng trên corpus cho thấy **quy tắc tốt hơn về độ chính xác, mô hình tốt hơn về độ bao phủ** — hướng đi là kiến trúc lai, không phải thay thế.