# Paper Chipper: element-type chunking

## arXiv:2402.05131 → thiết kế đánh giá riêng

Jimeno Yepes, A., You, Y., Milczek, J., Laverde, S., & Li, R. (2024). *Financial Report Chunking for Effective Retrieval Augmented Generation.* arXiv:2402.05131. Mức tin cậy nguồn: **B** (preprint, chưa tra được venue).

Phần sau của slide là *đo thật* trên `data/raw` của đồ án, chạy bằng `scripts/eval/` — không phải số liệu trích từ paper.

# Paper này là gì: cẩn thận về tên

## Hai thứ hay bị nhầm vào một

**Chipper** là *tên model nhận diện bố cục* (vision encoder-decoder kiểu Donut) của Unstructured. **Phương pháp** được paper gọi là **element-based chunking**.

## Paper

| | |
|---|---|
| Đơn vị | chunk theo **loại phần tử cấu trúc**: Title, Table, NarrativeText, ListItem… |
| Điểm nhấn | "best chunk size *without tuning*" — đổi đơn vị phân mảnh thay vì tuning độ dài. |
| Trạng thái | preprint → mức **B**. |

## Vì sao đọc nó

- Là **baseline đối chiếu** cho tầng chunking.
- Là mức "cấu trúc hóa" giữa *fixed-size* và *structural tất định*.
- Paper Peng (dual-granularity) là mức tiếp theo.

# Vấn đề paper đặt ra: fixed-size mất cấu trúc

## Ba hạn chế của RAG truyền thống

1. Coi mọi văn bản **bình đẳng** $\rightarrow$ bỏ thông tin nằm trong *cấu trúc* (tiêu đề, bảng).
2. Bảng bị **cắt ngang** $\rightarrow$ mất liên kết hàng–cột.
3. Phải **tinh chỉnh** `chunk size` thủ công; kích thước tối ưu đổi theo loại dữ liệu.

## Baseline của paper

- Fixed-size: $n \in \{128, 256, 512\}$ token.
- **Aggregation**: chạy nhiều cấu hình song song rồi gộp *kết quả truy xuất*.

## Cách phản biện

Paper *không* cải tiến fixed-size mà **đổi đơn vị phân mảnh** $\rightarrow$ khối có kích thước *tự thích ứng*, không cần tuning.

## Thiết kế thực nghiệm *sạch* (single-variable)

Toàn bộ pipeline RAG giữ nguyên, **chỉ bước chunking đổi**: PDF $\rightarrow$ **[1] chunking** $\rightarrow$ [2] indexing (Weaviate, `multi-qa-mpnet-base-dot-v1`) $\rightarrow$ [3] retrieval top-10 $\rightarrow$ [4] generation (GPT-4).

# Trái tim: thuật toán 4 bước

Từ JSON phần tử do Chipper xuất (mỗi phần tử có `type`, `bbox`, `text`), khối được sinh theo **bốn quy tắc**:

1. Nếu độ dài `text` của phần tử $< 2.048$ ký tự $\rightarrow$ thử **gộp** với phần tử kế tiếp.
2. Lặp lại đến khi đạt độ dài mong muốn $\rightarrow$ **nhưng không bao giờ cắt vỡ một phần tử**.
3. Gặp phần tử **TITLE** $\rightarrow$ **bắt đầu chunk mới**.
4. Gặp phần tử **TABLE** $\rightarrow$ bắt đầu chunk mới và **giữ nguyên toàn bộ bảng**.

## Hai điểm cần nhớ

- `2.048` là **ngưỡng để *coi là* chunk**, không phải độ dài cố định.
- Title & Table **buộc mở chunk mới** $\rightarrow$ ranh giới chunk trùng ranh giới *ngữ nghĩa*.

## "Không cần tuning"

**Không có tham số nào ngoài một ngưỡng độ dài.** Đây chính là luận điểm trong abstract — và cũng là điểm yếu bị phản biện ở slide sau.

# Metadata làm giàu khối: ba loại

Sau khi có chunk, paper sinh thêm metadata để hỗ trợ truy xuất:

| # | Loại | Cách sinh |
|---|---|---|
| 1 | Keywords | GPT-4, prompt template → tối đa **6 từ khóa** |
| 2 | Summary | GPT-4, prompt template → đoạn tóm tắt |
| 3 | Prefix & Table Desc. | **2 câu đầu** của khối; với bảng → **caption** |

## Loại 3 là loại *đáng lấy*

- **Rẻ nhất, tất định nhất** — không cần LLM.
- Cho **BLEU cao nhất** (0,400) trong ba loại đơn lẻ.

## Gợi ý trực tiếp cho pipeline hiện tại

**Caption bảng là tín hiệu truy xuất mạnh.**
Row-JSON lặp caption trong *mọi* dòng;
`chipper_prefix` thêm caption vào chunk.

# Dữ liệu đánh giá: FinanceBench

## Corpus

| | |
|---|---|
| Bộ | FinanceBench — open-book QA trên báo cáo **SEC** 10-K/10-Q/8-K **tiếng Anh**. |
| Dùng được | **141 câu hỏi / 80 tài liệu** (150/84 → mất 4 báo cáo không tải được). |
| Trang | tổng **11.787** trang; TB **147,34** trang/tài liệu (min 4, max 549). |
| Token | TB **102.444** token/tài liệu. |
| Bằng chứng | trang TB **54,58** (trải 1→304). |

## Chipper phân bố phần tử (tổng 146.921)

| Loại | SL | Loại | SL |
|---|---|---|---|
| NarrativeText | 61.780 | **Table** | **7.700** |
| ListItem | 33.054 | Header | 3.959 |
| Title | 29.664 | Footer | 1.026 |
| Uncategorized | 9.400 | Khác | 334 |

## Lưu ý khi so với corpus của đồ án

Bằng chứng nằm ở **trang TB 54** của tài liệu **147 trang** — bài toán ở paper là *tìm đúng trang*, còn đồ án là bảng **3–6 trang**. Hai miền hoàn toàn khác nhau.

# Kết quả paper (1): độ hiệu quả phân mảnh

## Số chunk

| Chiến lược | Tổng | Chunk/tài liệu |
|---|---|---|
| Base 128 | 64.058 | 800,73 |
| Base 256 | 32.051 | 400,64 |
| Base 512 | 16.046 | 200,58 |
| **Chipper** | **20.843** | **260,57** |

## Đọc

Chipper **gần Base 512** về số lượng → cùng chi phí index, nhưng **ranh giới có ý nghĩa ngữ nghĩa**.

## Hiệu quả chi phí

`Chipper Aggregation` đạt điểm cao nhất chỉ với **62.529 chunk** — bằng ≈ **một nửa** Base Aggregation (112.155).

## Nhưng…

Paper *không đo* TEDS hay chất lượng khôi phục cấu trúc bảng — nên **không biết bảng có bị méo không**, chỉ biết giữ "nguyên".

# Kết quả paper (2): truy xuất

| Chiến lược | #chunk | Page Acc | ROUGE | BLEU |
|---|---|---|---|---|
| Base 128 | 64.058 | 72,34 | 0,383 | 0,181 |
| Base 256 | 32.051 | 73,05 | 0,433 | 0,231 |
| Base 512 | 16.046 | 68,09 | 0,455 | 0,250 |
| Base Aggregation | 112.155 | 83,69 | 0,536 | 0,277 |
| Keywords Chipper | 20.843 | 46,10 | 0,444 | 0,315 |
| Summary Chipper | 20.843 | 62,41 | 0,473 | 0,350 |
| Prefix & Table Desc. Chipper | 20.843 | 67,38 | 0,514 | **0,400** |
| **Chipper Aggregation** | 62.529 | **84,40** | **0,568** | **0,452** |

**Nghịch lý page-level**

Fixed-size **thắng** ở page-level (72–73%) nhưng **thua** ở paragraph-level → "trúng trang nhưng *lệch đoạn*". Chipper **nhất quán** giữa hai mức.

**Aggregation**

Đỉnh cả ba chỉ số, **nhưng** paper tự thừa nhận nó **hại Q&A** do prompt vượt giới hạn token của GPT-4 → **không bê về**.

# Kết quả paper (3): Q&A accuracy

| Chiến lược | No answer | GPT-4 | Manual |
|---|---|---|---|
| Base 128 | 35,46 | 29,08 | 35,46 |
| Base 256 | 25,53 | 32,62 | 36,88 |
| Base 512 | 24,82 | 41,84 | 48,23 |
| **Keywords Chipper** | 22,70 | 43,97 | **53,19** |
| Summary Chipper | **17,73** | 43,97 | 51,77 |
| Prefix & Table Desc. | 20,57 | 41,13 | **53,19** |

## Tuyên bố của paper

**53,19%** = SOTA trên FinanceBench tại thời điểm công bố (so với ≈50% của baseline).

## Đọc "No answer"

Thấp nhất (17,73%) thuộc Summary Chipper → chunk theo phần tử **giữ ngữ cảnh đủ** để trả lời.

## Chênh lệch GPT-4 vs người chấm

**Có hệ thống**, đặc biệt với câu kèm *tính toán*: đáp án đúng $39{,}7\%$ nhưng model trả $39{,}73\%$ kèm lời giải → GPT-4 judge chấm **sai**.
⇒ Phải chấm tay; ROUGE/BLEU **chỉ để đối chiếu**.

# Phản biện: điểm yếu của paper

| Điểm yếu | Chi tiết |
|---|---|
| Phụ thuộc model nhận diện | Toàn bộ chất lượng chunk nằm ở **Chipper**. Chưa có checkpoint → không chạy được. |
| Miền Anh / có text layer | Corpus là SEC **tiếng Anh**; *không* kiểm chứng trên bảng **không viền tiếng Việt**. |
| Ngưỡng 2.048 còn cứng | Paper gọi là "desired length" nhưng **không phân tích độ nhạy**. |
| Không đo cấu trúc bảng | Giữ nguyên cả bảng nhưng **không đo TEDS**. |
| Không có venue | Bản arXiv, chưa rõ phản biện kín → mức **B**. |
| Q&A $\approx$ 53% | Vẫn nửa sai; câu *suy luận tính toán* là điểm yếu. |

**Điều trở thành "cửa" cho đồ án**

Ba điểm *trung tâm* nhất — phụ thuộc model, chỉ kiểm chứng trên Anh/PDF có text layer, và không đo cấu trúc bảng — đều **chưa chạm tới** bảng không viền tiếng Việt.

# Định vị: ba chiến lược chunking cạnh tranh

| | **Chipper** | **Peng et al.** | **Row-JSON** |
|---|---|---|---|
| **Đơn vị** | Phần tử bố cục | Đoạn văn (LLM gộp) | Một dòng bảng |
| **Nguồn cấu trúc** | *học* từ ảnh trang | *suy* ra bằng LLM | *khôi phục* từ HTML bảng |
| **Cần model?** | **Có** (Chipper) | **Có** (LLM) | **Không** — tất định sau parse |
| **Cần tuning?** | ngưỡng 2.048 | $\gamma$=1024, $\theta$=0.9 | không |
| **Bảng** | giữ *cả* bảng | cắt theo câu | header lặp trong *từng* dòng |

**Y chinh**

Row-JSON là biến thể **tất định, kiểm thử được** của cùng nguyên lý *structure-aware chunking* — áp cho **bảng không viền tiếng Việt**, thứ cả Chipper lẫn Peng đều **chưa chạm tới**.

Nguồn: `docs/Co_che_Chipper….md` mục 9.1–9.2.

# Đi sang phần đánh giá: tách biến

## Không có model Chipper → phải tách biến

Mục tiêu chỉ là *thuật toán chunking*, không phải model nhận diện. Cách làm (đúng như paper tự làm):

1. **Bỏ** model Chipper; thay phần tử bằng output `unstructured`: caption → Title, bảng HTML → Table, đoạn → NarrativeText.
2. **Áp** đúng 4 quy tắc của paper → chiến lược **element**.
3. **Giữ cố định** corpus, BM25, bộ câu hỏi → chênh lệch quy được về *đơn vị phân mảnh*.

## Được phép tuyên bố

"*Thuật toán chunking 4 quy tắc* của paper có tốt trên bảng tiếng Việt không?"

## *Không* được tuyên bố

"Chipper (toàn pipeline) tốt/hỏng trên corpus này" — vì mô hình nhận diện bố cục **chưa hề chạy**.

# Bốn chiến lược trên cùng một parser

| | Chiến lược | Nguyên tắc | #chunk |
|---|---|---|---|
| C | `chipper` | **4 quy tắc Chipper** trên element `unstructured` | 136 |
| D | `chipper_prefix` | C + caption / 2 câu đầu làm tiền tố | 136 |
| E | `dual_small` | hai tầng: câu/dòng + đoạn lớn; trả chunk nhỏ | 935 |
| F | `row_json` | mỗi dòng bảng = một JSON tự chứa | 332 |

## Thang "cấu trúc hóa"

- C/D: cấu trúc *nhận diện* (phần tử, cả bảng).
- E: cấu trúc *hai tầng* (câu/dòng $\rightarrow$ đoạn).
- F: cấu trúc *ô* (mỗi dòng = một object).

## Một quan sát cần chú ý

`chipper` chỉ sinh **136 chunk** cho 7 tài liệu vì ngưỡng 2.048 ký tự "nuốt" gần trọn mỗi báo cáo 3–6 trang; row-JSON tách thành **332** đơn vị nhỏ hơn.

# Bộ câu hỏi vàng: sinh tự động, không viết tay

## gen_gold_qa.py

1. Với từng bảng → tự nhận **cột entity** (mã CK) và loại **cột STT**.
2. Với từng ô số ở cột trả lời → sinh 1 fact (entity, cột, giá trị).
3. Sinh câu hỏi tiếng Việt theo template, kèm **kỳ + chỉ số** lấy từ tên file (Q2 2026, VN30…).

**130 câu** / 7 tài liệu / 10 bảng

`data/eval/gold_qa.jsonl`

## Quan trọng: gold *không* gắn vào chunk

Gold được định nghĩa ở mức **sự kiện** (file, bảng, dòng, cột) — *không* gắn `chunk_id`.

## Vì sao

Mỗi chiến lược sinh `chunk_id` *khác nhau*. Nếu gold gắn `chunk_id` thì **chỉ đánh giá được đúng chiến lược đã sinh ra gold** — không so sánh được.

## Ví dụ câu sinh được

*"Tỷ trọng mới của BSR kỳ Q2 2026 chỉ số VN30"* → gold: `value_raw = 0,87%`, `value_norm = 0.87`, trang 2.

# Thế nào là “trả lời đúng” với từng chiến lược

## Quy tắc liên quan *dựa trên nội dung* — không dùng `chunk_id`

Một chunk là **liên quan** với fact $(e, v)$ khi nó chứa *cả hai*:

$$\text{entity } e \in \text{text(chunk)} \quad \textbf{và} \quad \text{giá trị } v \in \text{numbers}\big(\text{text(chunk)}\big)$$

Số đọc theo quy tắc tiếng Việt (`parse_number`): chấm = nghìn, phay = thập phân.

## Ngụ ý của quy tắc này

Nếu fixed-size **cắt đứt** ranh giới giữa `BSR` và `0,87%` → **không chunk nào đúng** → recall giảm. Đúng cái *mình muốn đo*.

## Metric

- **Recall@k**: trong top-*k* có chunk đúng không.
- **MRR**: nghịch đảo vị trí của chunk đúng *đầu tiên*.
- BM25 thuần, **cùng tokenization** cho cả 4 chiến lược.

# Kết quả đo thật trên corpus tiếng Việt

| Chiến lược | #chunk | R@1 | R@3 | R@5 | R@10 | MRR |
|---|---|---|---|---|---|---|
| `chipper` (C) | 136 | 27,7% | 63,8% | 76,9% | 89,2% | 0,475 |
| `chipper_prefix` (D) | 136 | 36,9% | 67,7% | 77,7% | 89,2% | 0,535 |
| `dual_small` (E) | 935 | 66,1% | 75,4% | 78,5% | 86,2% | 0,723 |
| `row_json` (F) | 332 | **81,5%** | **90,0%** | **90,0%** | **90,0%** | **0,850** |

130 câu vàng · 7 tài liệu · BM25 thuần · `python scripts/eval/eval_three_methods.py`

## 1. Paper đúng

Chunk theo cấu trúc **vượt fixed-size** (paper); trên corpus này, `chipper` đạt R@5 76,9% nhờ giữ nguyên bảng.

## 2. Granularity thô

Giữ *cả bảng* vào 1 chunk → R@5 cao nhưng R@1 chỉ 27,7%: nhiều giá trị nằm chung, *khó biết ô nào đúng*.

## 3. Row-JSON thắng ở precision

1 chunk = 1 dòng bảng = 1 sự kiện → BM25 đưa đúng ô lên **#1**: R@1 **81,5%**, MRR 0,850.

# Đọc kết quả và những gì *không* nên tuyên bố

## Kết luận có thể giữ

1. Nguyên lý cốt lõi của paper — **chunk theo cấu trúc** — **đúng** trên bảng không viền tiếng Việt.
2. Ngược lại, **granularity quá thô** (cả bảng 1 chunk) làm giảm độ chính xác *top-1* cho câu hỏi trích ô.
3. Row-JSON sửa đúng điểm đó: **mỗi dòng = một chunk**.

## Ba hạn chế phải ghi rõ

1. C dùng **phần tử `unstructured`**, không chạy model Chipper.
2. Gold **sinh tự động** từ ô bảng của parser cũ $\rightarrow$ có lợi cho cấu trúc; cần $\approx$20 câu viết tay.
3. Chỉ đo **truy xuất** (BM25), **không đo** sinh câu trả lời; coverage parser 96,9%.

**Lưu ý:** không dùng ROUGE/BLEU làm chỉ số chính — paper cho thấy GPT-4 judge lệch hẳn so với người chấm.

# Các bước tiếp theo đề xuất

1. **Viết ≈20 câu vàng thủ công** để giảm bias của gold tự sinh — đây là việc cần người, không tự động được.
2. **Thêm dense (vector search)** để xem thứ hạng có đổi không — hiện `HybridIndex` đã có, chỉ chưa đưa vào eval.
3. **Đo consistency hai tầng** (page-level và paragraph-level cùng lúc) — bài học trực tiếp từ paper; hiện đã có cả hai bảng.
4. **Đưa caption bảng vào** `sparse_text` để BM25 khớp — khoản "nên làm" từ việc học từ Chipper.
5. **Chấm câu sinh trả lời** (cần lớp PoT/tool-calling) — cả ba chiến lược vẫn ≈53% ở paper.

**Cách chạy lại (không cần GPU, không tốn API)**

```
python scripts/ingest/parse_unstructured.py
python scripts/eval/eval_three_methods.py --no-dense
```

# Tài liệu tham khảo


Jimeno Yepes, A., You, Y., Milczek, J., Laverde, S., & Li, R. (2024).
Financial report chunking for effective retrieval augmented generation.
*arXiv preprint* arXiv:2402.05131.
https://arxiv.org/abs/2402.05131

Islam, P., et al. (2023).
FinanceBench: A new benchmark for financial question answering.
*arXiv preprint* arXiv:2311.11944.

Kim, G., et al. (2021).
Donut: Document understanding transformer without OCR.
*arXiv preprint* arXiv:2111.15664.

Peng, Q., & Luo, X. (2027).
Dual-granularity chunking and dynamic context augmentation.
*Expert Systems with Applications*, 332, 133546.


Nguồn số liệu paper: `docs/Co_che_Chipper_Financial_Report_Chunking.md` · Nguồn số liệu đo: `data/eval/` + `scripts/eval/`