Kiến trúc Chuyên sâu ColPali: Efficient Document Retrieval with Vision Language Models

Bóc tách Toán học, Biểu diễn Tensor, Cơ chế Huấn luyện & Pipeline Triển khai

Báo cáo Kỹ thuật Chuyên đề: Vision-Language Models in IR

Phòng Thí nghiệm Trí tuệ Nhân tạo & Xử lý Ngôn ngữ Tự nhiên

October 27, 2026

Nội dung Báo cáo Chuyên sâu

Phần I: Giới hạn của Pipeline Parsing

- Phân tích sai số tích lũy (error cascading)
- Mất mát thông tin cấu trúc 2 chiều
- Chi phí indexing của OCR/captioning

Phần II: Cấu trúc Mô hình ColPali

- SigLIP Vision Encoder & patch tokenization
- Linear projection & Gemma-2B
- Late interaction (MaxSim) & hàm mất mát
- Huấn luyện, chi phí, kết quả ViDoRe

Phần III: Thực nghiệm trên corpus tiếng Việt

- Thiết kế: 7 PDF, 27 trang, 130 câu hỏi
- Baseline BM25 / row-JSON / ColPali
- Recall@k, MRR ở mức trang

Phần IV: Kết luận & Hướng tiếp

- Khi nào nên (và không nên) dùng visual retrieval
- Fine-tune LoRA tiếng Việt, patch $\rightarrow$ bounding box

Paper: Faysse et al., *ColPali: Efficient Document Retrieval with Vision Language Models*, ICLR 2025 (arXiv:2407.01449)

Vì sao pipeline parsing là nút thắt?



Mỗi mũi tên là một nguồn lỗi; lỗi tích lũy (error cascading) theo chiều dài pipeline.

Bảng không kẻ

Parser dựa trên đường kẻ/whitespace: mất hàng, lệch cột, gộp 2 bảng song song.

Cấu trúc 2 chiều

Vị trí, font, màu, đường bao mang nghĩa. Chunk văn bản 1D xóa mất các tín hiệu này.

Chi phí

OCR/captioning: hàng chục giây/trang; khó scale lên triệu trang.

Kết luận của paper: *tối ưu pipeline ingestion* mang lại nhiều điểm hơn *tối ưu embedding model* (Table 2).

Bằng chứng định lượng: cùng benchmark, khác pipeline

Hệ thống (ViDoRe, TB 10 task)	nDCG@5	Recall@1	Index / trang	Ghi chú
SigLIP-So400m (vanilla)	51.4	39.7	nhanh	1 vector
BiSigLIP (fine-tune contrastive)	58.6	47.1	nhanh	1 vector
BiPali (PaliGemma + mean-pool)	58.8	45.6	nhanh	1 vector
Unstructured + OCR (BM25)	65.5	–	chậm	text chunk
Unstructured + OCR (BGE-M3)	66.1	–	chậm	text chunk
Unstructured + Captioning (BGE-M3)	67.0	–	rất chậm	VLM sinh mô tả
ColPali (late interaction)	**81.3**	**72.7**	**1 forward**	1030 vector/trang

Đọc bảng

Baseline mạnh nhất (Captioning + BGE-M3) đạt 67.0; ColPali +14.3 điểm. Khoảng cách lớn nhất ở các task *giàu thị giác*: bảng, biểu đồ, infographic.

Lưu ý phương pháp

Đây là số của paper trên ViDoRe (tiếng Anh/Pháp), **không** phải số trên corpus tiếng Việt của đồ án.

ViDoRe: benchmark cho retrieval *nhìn* tài liệu

10 task, 2 nhóm

Học thuật (tái sử dụng VQA): DocVQA, InfoVQA, TAT-DQA, arXivQA, TabFQuAD.
Thực tế (PDF công khai + query do Claude-3 Sonnet sinh, người lọc): Energy, Government, Healthcare, AI, Shift Project.

Quy mô

≈3.8k query, ≈8.3k trang; 100–1600 ứng viên/task.
Ngôn ngữ: tiếng Anh + tiếng Pháp.
Đơn vị retrieval: **trang** (page-level).

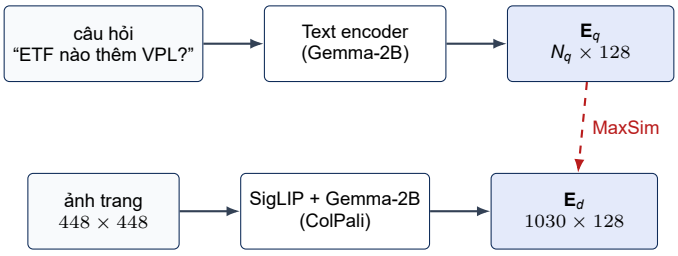
Vì sao cần benchmark riêng?

- Benchmark text retrieval đo *đoạn văn*, không đo trang.
- Benchmark ảnh tự nhiên (COCO, Flickr) không có bảng/biểu đồ.
- Hệ thực tế phải xử lý: scan, đa ngôn ngữ, bố cục phức tạp.

Chỉ số

nDCG@5 (chính), Recall@K, MRR; kèm latency truy vấn và throughput index.

Ý tưởng: Retrieval in Vision Space



Đầu vào là ảnh, không phải text

Mọi thứ nhìn thấy trên trang (bảng, biểu đồ, font, vị trí) đều đi vào embedding.

End-to-end

Tối ưu trực tiếp cho retrieval; không phụ thuộc chuỗi công cụ parse bên ngoài.

Backbone: PaliGemma-3B

Thành phần

- **Vision**: SigLIP-So400m/14, ảnh $448 \times 448 \Rightarrow 32 \times 32 = \mathbf{1024}$ patch.
- **Projector**: 1152 $\rightarrow$ 2048 (không gian ẩn của Gemma-2B).
- **Language**: Gemma-2B, full-block attention trên prefix (ảnh + instruction).
- **Head của ColPali**: linear 2048 $\rightarrow$ **128** + chuẩn hóa L_2.

Vì sao chọn PaliGemma?

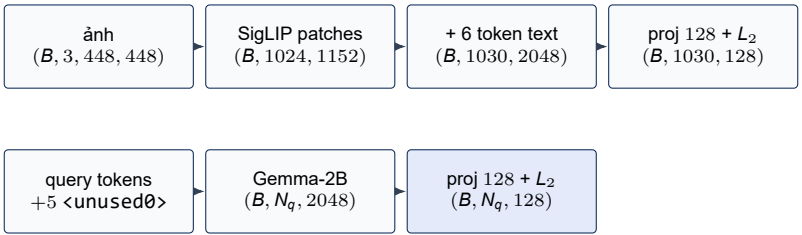
- Nhỏ (3B) nhưng mạnh trên tài liệu.
- Nhiều checkpoint cho nhiều độ phân giải.
- Patch đã được *alignment* với không gian text của LLM $\Rightarrow$ dùng được late interaction.

So sánh nhanh

SigLIP standalone: 729 patch (384px).
PaliGemma vision: 1024 patch (448px).

Trục quyết định: *1024 patch giữ được chữ nhỏ trong bảng*; giảm còn 224px (256 patch) mất 24.8 nDCG@5 (ablation).

Kiến trúc: đường đi của tensor



Con số đáng nhớ

1024 patch $+6$ token text $=$ **1030** vector/trang.
Mỗi vector 128 chiều, float16 $\Rightarrow$ **257.5** KiB/trang.

Hai nhánh dùng chung không gian

Query và patch đi qua *cùng* LM rồi cùng một projection $\Rightarrow$ tích vô hướng có nghĩa.

Vì sao multi-vector? Ba paradigm retrieval

	Bi-encoder	**Cross-encoder**	**Late interaction (ColBERT/ColPali)**
Biểu diễn tài liệu	1 vector	toàn bộ token	N_d vector (1030)
Query	1 vector	ghép với từng tài liệu	N_q vector
Chi phí online	1 phép nhân vô hướng	1 forward / tài liệu	$N_q \times N_d$ tích vô hướng
Chất lượng	thấp hơn	cao	gần cross-encoder
Latency	$\sim$ms	$\sim$100 ms–giây	$\sim$ms (engine tối ưu)
Index	nhỏ	không index được	lớn ($\sim$1000$\times$)

Điểm mấu chốt

Late interaction giữ được *tương tác từng token* (như cross-encoder) nhưng vẫn *tính trước* được embedding tài liệu (như bi-encoder). ColPali thay "token chữ" bằng "patch ảnh": mỗi patch là một đơn vị ngữ nghĩa thị giác.

Late interaction: công thức & trực giác

Định nghĩa

Với $\mathbf{E}_q \in \mathbb{R}^{N_q \times D}$, $\mathbf{E}_d \in \mathbb{R}^{N_d \times D}$, $D = 128$:

$$\mathrm{LI}(q, d) = \sum_{i=1}^{N_q} \max_{j=1}^{N_d} \langle \mathbf{E}_q^{(i)}, \mathbf{E}_d^{(j)} \rangle$$

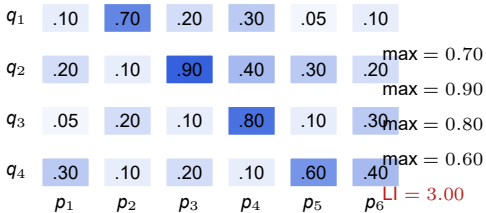
Mỗi token query chọn **patch giống nhất**, rồi cộng lại.

Độ phức tạp

$O(N_q\, N_d\, D)$ phép nhân. Với $N_q \approx 20$, $N_d = 1030$: $\approx$2.6M phép — rẻ hơn nhiều so với một forward 3B.

Khác bi-encoder

Không "nén" trang thành 1 vector: một trang có thể khớp nhiều khía cạnh của query.



Mỗi hàng = một token query; ô đậm = patch được chọn.

Hàm mất mát: contrastive với hard negative

Công thức (Eq. 2 trong paper)

Với batch $\{(q_k, d_k)\}_{k=1}^{b}$, đặt $s_k^+ = \mathrm{LI}(q_k, d_k)$ và $s_k^- = \max_{l \neq k} \mathrm{LI}(q_k, d_l)$ (negative khó nhất trong batch):

$$\mathcal{L} = -\frac{1}{b} \sum_{k=1}^{b} \log \frac{e^{s_k^+}}{e^{s_k^+} + e^{s_k^-}} = \frac{1}{b} \sum_{k=1}^{b} \log\left(1 + e^{s_k^- - s_k^+}\right)$$

Dạng `softplus` ổn định số học, tránh tràn khi $s^- - s^+$ lớn.

Vì sao hard negative?

Chỉ cần *một* negative khó nhất: tín hiệu học mạnh, ít nhiễu hơn softmax trên toàn batch. Ablation “No Pairwise” (dùng toàn batch negatives) giảm 1.6 nDCG@5.

Lan truyền ngược

max và $\sum$ đều khả vi (max chọn nhánh) $\Rightarrow$ huấn luyện end-to-end qua cả LM và vision encoder. Thực tế paper chỉ mở LoRA ở LM + projection.

Huấn luyện: dữ liệu & siêu tham số

Dữ liệu

118,695 cặp query–page:

- 63% từ train set học thuật công khai;
- 37% tổng hợp: PDF crawl web + câu hỏi giả do Claude-3 Sonnet sinh.

Hoàn toàn **tiếng Anh**; 2% tách làm validation.
Kiểm tra không trùng tài liệu với ViDoRe.

Query augmentation

Thêm 5 token `<unused0>` vào query như "soft query expansion". Bỏ đi: tiếng Anh gần như không đổi, nhưng tiếng Pháp giảm mạnh (Shift -9.8, TabFQuAD -6.3).

Siêu tham số

Epoch	1
Precision	bfloat16
LoRA	$r = 32$, $\alpha = 32$
Phạm vi LoRA	LM transformer + projection
Optimizer	paged AdamW 8-bit
LR	5×10^{-5}, linear decay
Warmup	2.5%
Batch	32
Phần cứng	8 GPU, data parallel

Nhận xét

Chỉ 1 epoch trên 119k cặp — nhỏ hơn nhiều so với contrastive pretraining của SigLIP.

Chi phí: index, truy vấn, bộ nhớ

Bộ nhớ (đánh đổi lớn nhất)

$1030 \times 128 \times 2$ byte $=$ **257.5** KiB/trang.
1 triệu trang $\approx$ 257 GB (chưa nén).
So với bi-encoder 1 vector 1024 chiều: $\sim$2 KiB/trang — gấp $\sim$125 lần.

Latency (NVIDIA L4)

ColPali query ($\sim$20 token)	30 ms
BGE-M3 query (15 token)	22 ms
Late interaction	1 ms / 1000 tr.
Index	4 trang / batch

Token pooling

Gộp các patch trùng thông tin (nền trắng): pool $\times 3 \Rightarrow$ giảm 66.7% số vector, giữ 97.8% hiệu năng. Tài liệu càng đặc chữ (Shift) càng kém chịu pooling.

So với pipeline parse

Bỏ được layout detection + OCR + chunking + captioning. Trang được embed *ngay* từ ảnh, throughput ổn định vì độ dài chuỗi cố định (1030 token).

Kết quả ViDoRe: nDCG@5 theo task

Hệ thống	arXivQA	InfoVQA	TabFQuAD	TAT-DQA	Shift	**TB**
SigLIP vanilla	43.2	64.1	58.1	26.2	18.7	51.4
BiSigLIP	58.5	70.5	62.7	30.5	26.5	58.6
BiPali	56.5	67.4	76.9	33.4	43.7	58.8
Unstructured+OCR (BGE-M3)	31.4	60.1	70.8	50.5	73.2	66.1
Unstructured+Captioning (BGE-M3)	35.7	71.9	69.1	43.8	73.1	67.0
ColPali	**79.1**	**81.8**	**83.9**	**65.8**	**73.2**	**81.3**

Nơi ColPali thắng đậm

arXivQA $+22.6$, InfoVQA $+14.4$, TabFQuAD $+7.0$ so với baseline mạnh nhất: đúng các task đòi hỏi đọc *hình* và *bảng*.

Nơi baseline còn cạnh tranh

Shift (văn bản dày, tiếng Pháp): 73.2 vs 73.1 — gần như hòa. Nghĩa là visual retrieval không miễn nhiễm với văn bản thuần.

Ablation: cái gì thực sự tạo ra điểm?

Biến thể	TB nDCG@5	Δ	Diễn giải
ColPali (448px, 1024 patch)	**81.3**	–	tham chiếu
ColPali 224px (256 patch)	56.5	-24.8	độ phân giải là yếu tố số 1
ColIdefics2 (64 patch)	76.6	-4.7	LLM 7B bù được ít patch
ColQwen2 (768 patch)	**86.6**	$+5.3$	backbone tốt hơn $\Rightarrow$ tốt hơn
Chỉ train trên DocMatix	79.1	-2.2	vẫn hơn baseline > 12 điểm
Không query-aug tokens	79.6	-1.7	EN gần như đổi; FR giảm mạnh
In-batch CE (thay pairwise)	79.7	-1.6	hard negative quan trọng
Unfreeze vision encoder	80.6	-0.7	không cần thiết ở quy mô này
+ 1552 mẫu bảng tiếng Pháp	81.7	$+0.4$	TabFQuAD $+2.6$, Recall@1 $+5$

Bài học

(1) Độ phân giải/patch count quan trọng hơn backbone; (2) late interaction là phần "bùng nổ" (BiPali $\rightarrow$ ColPali $+22.5$); (3) fine-tune rất rẻ và hiệu quả cho miền mới (chỉ 1552 mẫu đã $+2.6$).

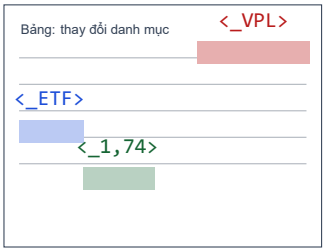
Khả năng diễn giải: patch nào khớp token nào?

Cách đọc heatmap

Với mỗi token query, tô đậm các patch có tích vô hướng cao nhất. Kết quả cho thấy ColPali *định vị* được chữ và cả yếu tố phi chữ.

Ví dụ trong paper

- Token <_hour> khớp cả “hourly” và “hours” ⇒ có năng lực OCR mờ.
- Trục hoành của biểu đồ (đơn vị giờ) cũng được tô đậm.
- Token <_Kazakhstan> khớp cả chữ “Kashagan” (mỏ dầu) ⇒ có tri thức thế giới.



Mô phỏng: token → vùng ảnh.

Giới hạn cần nêu trung thực

Về kỹ thuật

- **Chỉ trả về trang**, không trả về đoạn/bảng cụ thể. Muốn RAG cần thêm bước patch $\rightarrow$ bounding box.
- 1030 vector/trang: index lớn hơn bi-encoder $\sim$125 lần.
- 3B tham số: khó chạy trên CPU/edge; 1 forward/trang vẫn đắt hơn embed text.
- Phụ thuộc độ phân giải: 224px mất 24.8 điểm.

Về bằng chứng

- Train set 100% tiếng Anh; ViDoRe chỉ có Anh/Pháp $\Rightarrow$ tiếng Việt là *zero-shot*.
- Benchmark 100–1600 ứng viên/task, chưa chứng minh ở quy mô triệu trang.
- Không sinh câu trả lời: vẫn cần LLM/VLM phía sau.
- So sánh công bằng khó: baseline parse dùng thiết lập mạnh nhất của paper.

$\Rightarrow$ Câu hỏi cho đồ án: *zero-shot ColPali có thắng BM25 trên bảng không kể tiếng Việt?*

Thực nghiệm: thiết kế trên corpus tiếng Việt

Corpus & gold set

- 7 PDF đã parse: 3 broker forecast + 4 SSI review; 27 trang.
- 130 câu hỏi sinh từ 10 bảng (entity + value).
- Ví dụ: “VPB được mua bao nhiêu triệu cổ phiếu bởi quỹ ETF mô phỏng VN30?” → `1,74`.

Đơn vị đánh giá

Page-level (giống paper): mỗi câu hỏi có **1–3 trang vàng** (bảng trải trang). Trang vàng lấy từ text layer PyMuPDF, độc lập parser. Lý do: ColPali chỉ trả về trang; ép mọi hệ về cùng đơn vị để so sánh công bằng.

Hệ thống so sánh

1. **BM25 trang**: text element của `unstructured` trên trang → BM25.
2. **row-JSON / chipper / dual**: chunk → max-pool điểm lên trang.
3. **ColPali / ColSmol**: ảnh trang → multi-vector → MaxSim.

Metrics

Recall@$\{1, 3, 5, 10\}$, MRR (trang); latency encode + query; dung lượng index.

Triển khai: CPU-only, không API

Môi trường

- Python 3.11, `colpali-engine`, PyMuPDF (150 DPI).
- Không GPU: **ColSmol-256M** (cùng late interaction, backbone nhỏ) cho lượt chạy đầy đủ.
- SmolVLM cắt trang A4 thành 13 crop $512 \times 512 \Rightarrow$ 875 vector/trang.
- Chạy thêm **ColPali-v1.2** trên subset để kiểm tra xu hướng.

Vì sao chấp nhận được?

Câu hỏi là *so sánh tương đối* visual vs text retrieval, không phải tái lập SOTA.

Pipeline

```
imgs  = render(pdf, dpi=150)
ds    = [{"image": im} for im in imgs]
E_d   = model.embed(ds)          # 875x128 (ColSmol)
E_q   = model.embed_queries([q]) # Nq x 128
score = maxsim(E_q, E_d).sum()
```

Lưu ý

Chuẩn hóa L_2 hai phía; dùng `ColPaliProcessor` để resize đúng 448px.

Kết quả trên corpus tiếng Việt

Hệ thống (xếp hạng toàn bộ 27 trang)	R@1	R@3	R@5	R@10	MRR
BM25 theo trang (`unstructured`)	4.6	22.3	41.5	75.4	0.227
chipper_prefix (max-pool)	45.4	89.2	99.2	100.0	0.665
dual_small (max-pool)	73.9	96.2	100.0	100.0	0.844
row_json (max-pool)	**90.0**	**100.0**	**100.0**	**100.0**	**0.950**
ColSmol-256M (zero-shot)	13.8	26.9	36.2	74.6	0.288
ColPali-v1.2 (zero-shot)	*chưa chạy — cần GPU*				

Trang vàng lấy từ text layer PyMuPDF (1–3 trang/câu), không dùng trang bắt đầu bảng; vì thế số khác bản cũ.

Đọc kết quả

Visual zero-shot **vượt BM25 trang** ở R@1 (13,8% vs 4,6%) — tín hiệu ảnh có thật. Nhưng còn cách row-JSON **6,5 lần** (90,0%) và dual_small (73,9%). Nguyên nhân: 256M, train tiếng Anh, 27 trang bảng số gần như giống nhau.

Phạm vi từng file (27 trang → 3–6 trang)

BM25: R@1 17,7%, MRR 0,528.
ColSmol: R@1 20,8%, MRR 0,547.
Visual vượt BM25 ở R@1 nhưng vẫn rất thấp; đây là protocol dễ hơn, con số chính vẫn là corpus-level.

Kết luận & hướng tiếp theo

Ba bài học từ paper

1. Nút thắt của RAG tài liệu là *ingestion*, không phải embedding model.
2. Ảnh hóa tài liệu + late interaction cho phép bỏ hẳn parser/OCR/chunking.
3. Độ phân giải (số patch) là đòn bẩy lớn nhất; fine-tune miền mới rất rẻ.

Hướng tiếp cho đồ án

- Fine-tune LoRA ColPali trên cặp (câu hỏi, trang) tiếng Việt.
- Ánh xạ patch $\rightarrow$ bounding box để trả về đúng bảng (không chỉ trang).
- Thử ColQwen2 / ColSmol; nén index bằng token pooling.
- Kết hợp: visual retrieval lấy trang, row-JSON lấy ô — hybrid 2 tầng.

Tài liệu tham khảo

- Faysse, Sibille, Wu, Omrani, Viaud, Hudelot, Colombo. *ColPali: Efficient Document Retrieval with Vision Language Models*. ICLR 2025. arXiv:2407.01449.
- Khattab & Zaharia. *ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT*. SIGIR 2020.
- Beyer et al. *PaliGemma: A Versatile 3B VLM for Transfer*. arXiv:2407.07726.
- Alabdulmohsin et al. *SigLIP: Sigmoid Loss for Language Image Pre-training*. ICCV 2023.
- Clavié, Chaffin, Adams. *Reducing the Footprint of Multi-Vector Retrieval with Minimal Performance Impact via Token Pooling*. arXiv:2409.14683.
- Faysse et al. *ViDoRe benchmark & leaderboard*. `https://huggingface.co/vidore`.

Ghi chú số liệu

Mọi con số ở Phần I–II lấy từ arXiv:2407.01449v3 (Table 2, 6, 7). Số ở Phần III do đồ án tự đo trên corpus riêng, **không** so sánh trực tiếp với ViDoRe.