Dual-Granularity Chunking & Dynamic Context Augmentation

Peng & Luo (2027), *Expert Systems with Applications*

Peng, Q., & Luo, X. (2027). *Dual-granularity chunking and dynamic context augmentation: An optimization method for retrieval-augmented generation.* *Expert Systems with Applications*, 332, 133546. DOI: 10.1016/j.eswa.2026.133546

Nhận bài 15/05/2025 · bản sửa 17/06/2026 · chấp nhận 03/07/2026 · online 10/07/2026

Câu hỏi

*"Làm sao để hệ thống biết **chính xác chỗ nào** cần tìm,*
*mà vẫn đưa cho LLM **đủ ngữ cảnh** để trả lời?"*

Câu trả lời của bài báo: **dùng hai cấp độ đo đơn vị khác nhau.**

Khối nhỏ *S* — *đơn vị tìm kiếm*

- ngắn, cụ thể → **khớp câu hỏi chính xác**
- đưa vào chỉ mục để so khớp
- chỉ dùng để *chọn* đoạn cần đọc, *không* dùng để sinh

Khối lớn *L* — *đơn vị sinh nội dung*

- dài, đủ ngữ cảnh → **giải thích được câu hỏi**
- đưa vào prompt cho LLM đọc
- mỗi khối nhỏ **luôn trỏ về** đúng khối lớn cha của nó

Câu hỏi mà cả bài báo tập trung trả lời

Làm sao xây được cả hai loại đơn vị đó một cách *tự động*, từ tài liệu thô?

Một ví dụ để thấy ngay vấn đề

Câu hỏi: **“Cấp độ A bị loại khi nào?”** — chỉ nói về điều kiện 2, nhưng đoạn gốc có ba điều kiện.

Khối lớn L — cả đoạn, đưa cho LLM đọc

ĐK1: thành phần hóa học đúng theo bảng 3.

ĐK2: không được có vết nứt hay vết lõm trên bề mặt.

ĐK3: siêu âm không phát hiện khuyết tật bên trong.

Ba khối nhỏ — đưa vào chỉ mục để tìm

S_1: hóa học

S_2: **vết nứt, vết lõm trên bề mặt**

S_3: khuyết tật bên trong

Không tìm bằng L

L chứa cả 3 điều kiện $\rightarrow$ **2/3 là nhiễu**, điểm khớp giảm.

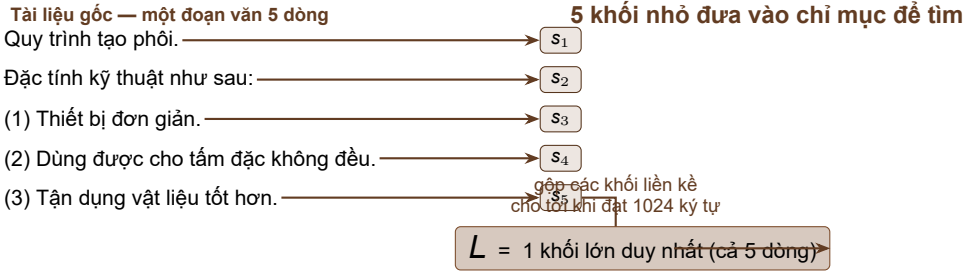
Không sinh bằng S

S_2 đúng ý nhưng quá ngắn, không giải thích được vì sao $\rightarrow$ LLM **cụt hoặc bịa**.

small2big: cứ theo dòng mà cắt

small2big (Gao et al., 2023) là *nền tảng* mà bài báo này dựng lên. Nguyên tắc duy nhất của nó rất đơn giản:

1 dòng văn bản = 1 khối nhỏ



Khi người dùng hỏi, hệ thống tìm trên *5 khối nhỏ*; trúng s_i nào thì đưa *cả khối lớn L* cho LLM đọc.

Nhưng đoạn trên đã bị cắt đúng một chỗ rất quan trọng

Cùng đoạn 5 dòng đó, hãy nhìn **hai ô đánh dấu đỏ**.

Lỗi 1 — tiêu đề thành một khối *rỗng*

s_2 = "Đặc tính kỹ thuật như sau:"

Đây là một **tên mục**, không có nội dung nào đi kèm. Người dùng gõ tìm "đặc tính kỹ thuật" → hệ thống trả về đúng s_2 — **một dòng không có nội dung**. Muốn biết đặc tính gì thì phải đọc tiếp.

Lỗi 2 — vế (2) mất chủ ngữ

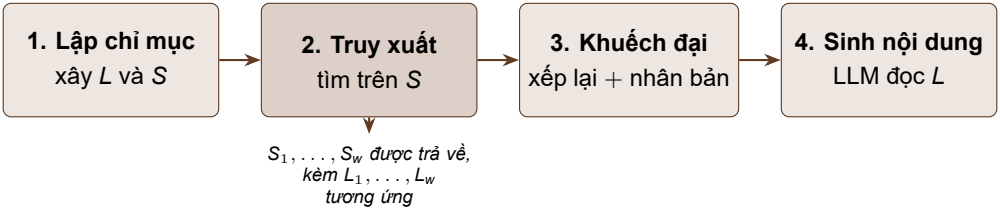
s_4 = "(2) Dùng được cho tấm đặc không đều."

Đọc riêng s_4 thì **không biết**: đây là của *cái gì*, là *đặc tính gì*. Cả hai thông tin đó đều nằm ở s_2 — *một dòng khác*.

Y chinh

Ranh giới *dòng* không phải ranh giới *nghĩa*. Chỗ bài báo này sửa chính là chỗ đó.

Kiến trúc: bốn giai đoạn



- Kết quả truy xuất là *cặp*: $(S_1, L_1), (S_2, L_2), \ldots, (S_w, L_w)$, với $w = 4$.
- Giai đoạn 3 xử lý **trên khối lớn**, vì đó là thứ đưa vào prompt.
- Toàn bộ ý tưởng chỉ là: **cùng một tài liệu, hai cách đo đơn vị**.

Cơ chế 1a — Khối lớn *L* là cái gì

L là **một đoạn văn trọn vẹn**, gom nhiều câu có cùng chủ đề, dài tối đa 1024 ký tự. Đây là thứ đưa cho LLM đọc.

Ba bước để xây một *L*

1. **Tách thành đơn vị văn bản.** Một dòng *kết thúc bằng dấu câu* (“.”, “!”, “?”) mới là một đơn vị. Ngược lại, tiêu đề thường *xuống dòng* nhưng là đầu một chủ đề mới.
2. **Gộp các đơn vị thành đoạn văn bằng LLM.** Hỏi LLM “hai đơn vị có cùng một đoạn không?” như một bài *phân loại*, trả lời Có/Không.
3. **Gộp các đoạn thành khối lớn** nếu tổng độ dài chưa vượt trần *Y*: độ dài(L_i) + độ dài$(L_{i+1}) \leq Y$, với $Y = 1024$.

Kết quả trông như thế nào

```
L1 = ``Quy trình tạo phôi.''
L2 = ``Đặc tính kỹ thuật như sau: (1) Thiết bị
đơn giản.
       (2) Dùng được cho tấm đặc không đều.
       (3) Tận dụng vật liệu tốt hơn.''
```

Y là gì

Y là *trần độ dài* của một khối lớn, tính bằng ký tự. Vượt trần thì khởi đầu một *L* mới. Không phải câu hỏi, không phải điểm số — chỉ là **độ dài**.

Bước đắt nhất

Bước 2 là bước **duy nhất** phải gọi LLM, và phải gọi *một lần cho mỗi cặp câu liền kề*.

Bước 2 làm gì: ví dụ về gạch đầu dòng

Cùng một đoạn văn, xử lý hai cách (bảng 2 của bài báo):

Không có bước 2

Đoạn 1. Quy trình tạo phôi.
Đoạn 2. Đặc tính kỹ thuật như sau:
Đoạn 3. (1) Thiết bị đơn giản.
Đoạn 4. (2) Dùng được cho tấm đặc không đều.
Đoạn 5. (3) Tận dụng vật liệu tốt hơn.

⇒ **5 đoạn vụn**, cùng một chủ đề bị băm vỡ.

Có bước 2

Đoạn 1. Quy trình tạo phôi.
Đoạn 2. Đặc tính kỹ thuật như sau:
Đoạn 3. (1) Thiết bị đơn giản, tải trọng nhỏ. (2) Dùng được cho tấm đặc không đều. (3) Tận dụng vật liệu tốt hơn.

⇒ **3 đoạn trọn vẹn**, chủ đề giữ nguyên.

Vì sao lại hợp lý

LLM được dạy bằng tiền đề (prompt learning) và ví dụ mẫu (few-shot) để biết khi nào hai mục *cùng một đoạn* — mà quy tắc cú pháp không bắt được điều đó.

Bước 2 gọi LLM bằng cách nào — lời nhắc và ví dụ mẫu

Không huấn luyện lại LLM. Chỉ **gửi kèm một đoạn hướng dẫn** (lời nhắc, *prompt*) rồi hỏi. Ở đây câu hỏi được *gộp sẵn*:

[Hướng dẫn] *Hai mục dưới đây có thuộc cùng một đoạn văn không? Trả lời đúng* `Yes` *hoặc* `No`*, không giải thích thêm.*
[Ví dụ 1] *Đầu mục "3.2 Thiết bị" + mục "3.2.1 Đầu lò thảo"* $\rightarrow$ `Yes`
[Ví dụ 2] *Mục "1. Giới thiệu" + mục "2. Điều lệ"* $\rightarrow$ *No*
[Cần phân loại] *"2. Đặc tính kỹ thuật" + "(1) Thiết bị đơn giản"* $\rightarrow$ *?*

$n = 10$ nghĩa là gì

Không phải 10 lần gọi. Đó là **10 cặp ví dụ có sẵn** như Ví dụ 1 và Ví dụ 2 — nằm *trong* lời nhắn để LLM biết "cùng một đoạn" trông như thế nào. Bài báo dùng $n = 10$. *Mục 4.7.3 sẽ thử các giá trị n khác.*

Quy tắc: `Yes` khi *cả ba* điều kiện đúng

1. cùng là *danh sách có số thứ tự*, hoặc một bên là danh sách ngầm kiểu "có ba loại: A, B và C";
2. tiêu đề cha *giống hệt* cả chữ và cấp (3.2 so với 3.2.1);
3. cùng một *chiều* (cùng nói về phân loại, cùng nói về tiêu chuẩn, …).

Quy tắc: `No` khi

khác cấp tiêu đề (2 so với 2.1); liên quan chéo mục; hoặc lệch chiều mô tả — một bên nói về phương pháp tẩy, bên kia nói về tác động môi trường.

Cơ chế 1b — Khối nhỏ S là cái gì

S là **một hoặc vài câu có nghĩa trọn vẹn**, tách ra từ chính khối lớn *L*. Đây là thứ đưa vào chỉ mục để tìm.

1. **Tách *L* thành câu** theo dấu câu (“.”, “?”, “!”).
2. **Gộp hai câu liền kề** nếu chúng cùng nói một ý:

$$c = s_l \oplus s_{l+1} \quad \text{nếu} \quad \cos(s_l, s_{l+1}) \geq \theta, \qquad \theta = 0{,}9$$

Kết quả trên cùng ví dụ

S_1 “Đặc tính kỹ thuật như sau:”
S_2 “(1) Thiết bị đơn giản, tải trọng nhỏ.”
S_3 “(2) Dùng được cho tấm đặc không đều.”
S_4 “(3) Tận dụng vật liệu tốt hơn.”

$S_1 \ldots S_4$ *đều thuộc về cùng một khối lớn* L_2.

Vì sao *gộp* mà không cứ tách câu làm khối nhỏ?

Khối nhỏ phải *đủ nghĩa để trả lời được một câu hỏi.* Một câu nói “Điều kiện đó là …” thì không đứng được một mình.

cos và θ

$\cos(a, b) \in [-1; 1]$ là *độ giống nhau* giữa hai câu, đo bằng mô hình nhúng `bge-large-zh-v1.5`. $\theta = 0{,}9$ là **ngưỡng chặt**: chỉ gộp khi hai câu gần như nói cùng một việc.

Cơ chế 2a — Xếp hạng lại trên cả hai cấp độ

Vấn đề

Thứ hạng sau giai đoạn 2 mới tính từ $\cos(Q, S_i)$. Mà S_i rất ngắn, nên nó chưa nói hết ý → thứ hạng có thể **sai**.

$$S_i' \;=\; \frac{1}{2}\Big(\cos(Q, S_i) \;+\; \cos(Q, L_i)\Big)$$

Vì sao trung bình lại hợp lý

- $\cos(Q, S_i)$ bắt được **chi tiết** nào khớp câu hỏi.
- $\cos(Q, L_i)$ bắt được **ý nghĩa chung** của đoạn.
- Trung bình → đoạn nào vừa khớp chi tiết vừa đúng ngữ cảnh thì lên đầu bảng xếp hạng.

Lưu ý khi đọc kết quả

Ở nhóm thí nghiệm chỉ dùng `small2big`, *chỉ khối lớn* đôi khi còn tốt hơn trung bình ở ROUGE-1/ROUGE-L. Chỉ khi dùng đồng thời cả cơ chế 1 thì phép trung bình mới thắng trên **cả bốn chỉ số** (xem slide sau).

Cơ chế 2b — Nhân bản ngữ cảnh: in lại khối đứng đầu

Vấn đề

LLM đọc prompt *theo thứ tự*. Đoạn nào nằm **sát đầu** và **lặp lại** thì dễ được chú ý hơn — đặc biệt khi đoạn đó đúng là đoạn khớp câu hỏi nhất.

Khối lớn	**Điểm sau xếp lại** S_i'
L_1	**0,71** ← đứng đầu
L_2	0,63
L_3	0,58
L_4	0,55

Không nhân bản

L1 *— 0,71. LLM chỉ nhìn nó một lần.*

Có nhân bản

L1 *— 0,71.* ***L1*** *— 0,71. LLM chỉ nhìn nó hai lần.*

Không đổi nội dung LLM đọc — chỉ đổi mức độ chú ý. Nó là một mẹo (heuristic) rẻ, không cần huấn luyện gì thêm.

Khi nào thì nhân bản — ba cách chọn, và τ là gì

Cả ba cách đều trả lời cùng một câu: *mục đầu bảng xếp hạng có đáng được nhấn mạnh không?*

(1) Theo ngưỡng τ

Điểm của mục đầu $> \tau$ thì nhân bản. Nếu không có mục nào đủ điểm thì *không* nhân bản.

(2) Theo độ lệch chuẩn

Tính trung bình μ và độ lệch chuẩn σ của *tất cả* điểm. Nhân bản nếu điểm mục đầu $> \mu + \sigma$. Tự thích nghi theo bộ kết quả, không cần chọn ngưỡng.

(3) Theo độ khác biệt

Với mọi L_j, tính $D(L_j) =$ trung bình $\cos(L_j, L_k)$, $k \neq j$. Chọn 2 khối có D thấp nhất. Mục đầu nằm trong đó $\rightarrow$ nhân bản. Đo tính *độc đáo*, không đo điểm.

τ (tau) là cái gì

τ là **một con số ngưỡng**, không phải tên hàm. Giá trị mặc định của bài báo là $\tau = 0{,}4$, trên thang điểm $\cos$ trong khoảng $[-1; 1]$ — tức "chỉ nhân bản khi đoạn đó khớp mạnh". Nhỏ hơn thì nhân dễ hơn, lớn hơn thì nhân ít hơn. Tác giả cũng nói τ **cần chỉnh theo từng tập dữ liệu**.

Nguồn cảm hứng: pseudo-labelling (Arazo et al., 2020)

Không hề huấn luyện gì thêm — chỉ mượn ý tưởng *dùng chính tín hiệu của hệ thống làm chỉ báo để điều chỉnh đầu vào*.

Bối cảnh thí nghiệm

Dữ liệu

- Tài liệu nội bộ của một công ty thương mại điện tử về thép.
- Chuyên gia lĩnh vực tự tay soạn và kiểm tra **500 cặp hỏi–đáp**.
- Nội dung: thành phần, tính chất, ứng dụng, nguyên nhân khuyết tật.

Thiết bị

- FlashRAG, một GPU RTX 6000 24 GB.
- Thí nghiệm chính dùng **giải mã tham lam** — tất định với đầu vào cố định.

Hai bộ sinh

- LLaMA-3-Chinese-8B-Instruct
- Qwen2.5-7B-Instruct

Bốn chỉ số

- ROUGE-1, ROUGE-2, ROUGE-L — báo cáo dạng **F1**.
- BLEU-4, với $w_1 = \cdots = w_4 = 0{,}25$.

Bốn chỉ số đo bằng cách nào — ROUGE và BLEU

Bài này là QA *có đáp án tham khảo chuẩn*, nên cách đo là: **lấy câu trả lời của hệ thống, so với đáp án chuẩn, đếm phần trùng lặp**.

Đáp án chuẩn: `Ve số liệu tăng trong quý II` Câu trả lời: `Ve số liệu quý II tăng mạnh`

ROUGE — trùng lặp *trong câu trả lời*

ROUGE-1 trùng **từ đơn** (không quan tâm thứ tự)
ROUGE-2 trùng **cặp từ liền nhau** (giữ thứ tự) *Với ví dụ*
ROUGE-L trùng **cụm từ chung** dài nhất (LCS)
trên: R-1 khớp `Ve, số, liệu, II`; R-2 và R-L khớp `số liệu` → `II`.

BLEU-4 — trùng *cụm 4 từ*, có phạt độ dài

Giống ROUGE-2 nhưng nhìn **cụm 4 từ**, và *phạt* nếu câu trả lời quá ngắn so với đáp án chuẩn ($w_1 = \cdots = w_4 = 0{,}25$). Thường *thấp hơn* ROUGE và nghiêng về độ dài.

Điểm cần nói thẳng

Cả bốn chỉ số **chỉ đo trùng lặp từ ngữ**, không hiểu nghĩa. Điểm cao *không kéo theo* câu trả lời đúng — và ngược lại, câu trả lời đúng nhưng diễn đạt khác vẫn bị trừ điểm. Bài báo báo cáo ROUGE dạng F1.

Tham số thí nghiệm

Ký hiệu	Giá trị	Ý nghĩa
mô hình nhúng	`bge-large-zh-v1.5`	đo độ tương đồng và truy xuất vector
Y	1024	ngưỡng gộp hai đoạn thành khối lớn (3.3.1)
θ	0,9	ngưỡng cosine để gộp hai câu thành khối nhỏ (3.3.2)
w	4	số cặp (S, L) được trả về (3.4)
n	10	số ví dụ mẫu trong lời nhắc; giữ cố định trừ thí nghiệm riêng
độ dài đầu ra	512	độ dài tối đa LLM được sinh

Chi phí lập chỉ mục

Mỗi cặp đơn vị liền kề phải gọi LLM một lần $\rightarrow$ *chi phí lập chỉ mục cao hơn hẳn* cách chia theo quy tắc.

Phạm vi

Mô hình nhúng *tiếng Trung*; bài không đề cập đa ngôn ngữ. Miền dữ liệu chỉ có thép. Hai điểm này giới hạn khả năng khái quát hoá.

Kết quả 1 — So với các phương pháp RAG khác

LLaMA-3-Chinese-8B-Instruct làm bộ sinh (bảng 4). Rút gọn các dòng tiêu biểu:

Phương pháp	R-1	R-2	R-L	BLEU-4
Không truy xuất (chỉ LLM)	31,15	11,32	23,46	6,38
REPLUG	53,33	35,00	44,85	23,21
Selective Context	59,38	44,82	52,33	31,37
IRCoT	61,62	47,25	52,91	36,60
FLARE	61,22	46,20	53,88	35,33
SKR	66,82	52,10	59,53	41,38
RAG tiêu chuẩn (`small2big`)	67,41	52,80	60,09	42,01
ITER-RETGEN *(mạnh nhất nhóm cơ sở)*	67,60	53,73	60,59	42,73
Bài báo (ngưỡng)	**68,93**	**54,99**	**61,75**	**43,97**
Bài báo (độ lệch chuẩn)	68,89	54,99	61,61	43,98
Bài báo (khác biệt khối)	68,88	54,87	61,53	43,80

So với ITER-RETGEN: $+1{,}33$ / $+1{,}26$ / $+1{,}16$ / $+1{,}24$ *điểm. Cải thiện nhỏ, nhưng đồng bộ trên cả bốn chỉ số và cả hai bộ sinh.*

Kết quả 2 — Vì sao phải đổi cách chia khối

Bảng 8: giữ nguyên khung RAG tiêu chuẩn, *chỉ thay đổi cách chia khối*.

Cách chia khối	R-1	R-2	R-L	BLEU-4
Cố định 512 ký tự	61,36	45,41	53,49	34,85
Cửa sổ trượt (chồng 256)	64,97	50,57	57,93	40,02
Đoạn văn (theo xuống dòng)	59,98	46,43	53,24	32,94
Gộp đoạn có giới hạn 512	63,75	48,99	56,27	37,00
`small2big`	67,41	52,80	60,09	42,01
Của bài (hai cấp)	**68,53**	**54,54**	**61,39**	**43,06**

Đọc bảng này thế nào

Chênh lệch giữa cách tệ nhất và tốt nhất lên tới **8,55 điểm ROUGE-1**. Cách chia khối quan trọng ngang với việc dùng mô hình nào.

Nhưng phần cải thiện nhỏ

So với `small2big`, bài chỉ thắng **1,12 điểm ROUGE-1**. Phần lớn khoảng cách đã có sẵn từ `small2big`.

Kết quả 3 — Phân rã từng thành phần

Bảng 6: cộng dồn từng cơ chế vào RAG tiêu chuẩn. Số trong ngoặc là mức tăng so với dòng 1.

#	Cấu hình	R-1	R-2	R-L	BLEU-4
1	RAG tiêu chuẩn (`small2big`)	67,41	52,80	60,09	42,01
2	+ xây khối lớn mới	68,40 (+0,99)	54,39 (+1,59)	61,24 (+1,15)	43,01 (+1,00)
3	+ xây khối nhỏ mới	67,59 (+0,18)	53,13 (+0,33)	60,30 (+0,21)	42,37 (+0,36)
4	+ chia hai cấp (2 + 3)	68,53 (+1,12)	54,54 (+1,74)	61,39 (+1,30)	43,06 (+1,05)
5	+ xếp hạng lại hai cấp	67,97 (+0,56)	53,66 (+0,86)	60,57 (+0,48)	42,96 (+0,95)
6	+ nhân bản ngữ cảnh	67,89 (+0,48)	53,74 (+0,94)	60,67 (+0,58)	43,15 (+1,14)
7	+ mở rộng ngữ cảnh (5 + 6)	67,93 (+0,52)	53,91 (+1,11)	60,78 (+0,69)	43,30 (+1,29)
8	**Đầy đủ (4 + 7)**	**68,89** (+1,48)	**54,99** (+2,19)	**61,61** (+1,52)	**43,98** (+1,97)

*Cột **R-L**: dòng 3 chỉ $+0{,}21$ — đóng góp của xây khối nhỏ khi đứng một mình là rất nhỏ. Phần lớn cải thiện đến từ xây khối lớn ($+1{,}15$). Đây là điểm cần nói thẳng khi bảo vệ luận văn.*

Kết quả 4 — Phép trung bình có thật sự tốt không

Bảng 9: so ba cách xếp hạng. Nhóm trên chỉ dùng `small2big`; nhóm dưới dùng kèm chia hai cấp.

#	Cách xếp hạng	R-1	R-2	R-L	BLEU-4
Nhóm trên — khung chỉ có `small2big`					
1	không xếp lại (chỉ *S*)	67,41	52,80	60,09	42,01
2	chỉ dùng *L*	**67,88**	53,70	**60,77**	42,74
3	trung bình *S* và *L*	67,97	**53,66**	60,57	**42,96**
Nhóm dưới — đã có chia hai cấp					
4	không xếp lại + nhân bản	68,58	54,58	61,09	43,46
5	chỉ dùng *L* + nhân bản	68,73	54,89	61,44	43,68
6	**trung bình *S* và *L* + nhân bản**	**68,89**	**54,99**	**61,61**	**43,98**

Nhận xét phê bình — nói thẳng

Ở nhóm trên, phép trung bình *không* thắng ở ROUGE-1 và ROUGE-L. Chỉ khi có cơ chế 1 thì trung bình mới thắng trên *cả bốn* chỉ số. Nói khác: **phép trung bình chỉ hữu ích khi *S* và *L* thực sự bổ sung cho nhau** — phần đóng góp lớn nhất vẫn thuộc về cơ chế chia hai cấp độ.

Kết quả 5 — Hai tham số nhạy cảm

Số ví dụ mẫu *n* (0 đến 12)

- $n = 0$ (không ví dụ) vẫn đạt kết quả khá $\Rightarrow$ lời nhắc tự nó đã đủ hướng dẫn.
- Xu hướng **rơi** $\rightarrow$ **tăng** $\rightarrow$ **rơi**.
- Ít ví dụ: LLM bám quá ví dụ. Nhiều ví dụ: ví dụ thừa gây nhiễu.

Đây là điểm có lợi cho đề tài: bước đắt nhất vẫn cho kết quả tử tế khi bỏ hẳn.

Ngưỡng τ của cách (1) (0 đến 0,9)

- $\tau \in [0; 0{,}5]$: bốn chỉ số ổn định, gần tốt nhất.
- $\tau > 0{,}6$: giảm rõ, rõ nhất ở $\tau = 0{,}7$ và $0{,}8$.
- $\tau = 0$ tức *luôn* nhân bản — vẫn tốt.

Ngưỡng quá chặt $\rightarrow$ nhân quá ít $\rightarrow$ mất tác dụng. Tác giả tự nhận điều này giới hạn khả năng khái quát.

Nhận xét phê bình về bài báo

Điểm mạnh

- Cơ chế xếp hạng lại có lý lẽ rõ, giải đúng mâu thuẫn nhỏ–lớn.
- Phân rã thành phần *kỹ*, kết quả trong bảng 6 đọc được ngay.
- Thử trên hai bộ sinh $\rightarrow$ không phải hiệu ứng của một model.
- Báo cáo độ lệch chuẩn $\rightarrow$ chứng minh kết quả ổn định.

Hạn chế

- Một miền duy nhất (thép), 500 cặp, không kiểm tra miền khác.
- Mỗi cặp đơn vị liền kề gọi LLM $\rightarrow$ **chi phí lập chỉ mục cao**.
- Mô hình nhúng tiếng Trung $\rightarrow$ không nói gì về đa ngôn ngữ.
- Biên độ cải thiện chỉ $\approx 1{,}5$ ROUGE-L.
- Ngưỡng τ cần chỉnh theo từng tập dữ liệu.

Cơ hội cho đề tài

Hai hạn chế đầu — **miền dữ liệu** và **chi phí lập chỉ mục** — đều là thứ pipeline hiện tại đang ở vị thế khác.

Áp dụng vào đồ án — cặp S/L cho bảng

Bối cảnh: trả lời câu hỏi tài chính trên **báo cáo phân tích ETF tiếng Việt**, nội dung chính là **bảng số liệu không có đường viền** (borderless).

Khối lớn L — ngữ cảnh đưa cho LLM đọc

- Bảng/card: caption + toàn bộ nhãn cột + các dòng.
- Prose gộp tới $\gamma = 1.024$ ký tự; `Title`/`Table` là ranh giới cứng.
- Khi trả về: chunk lớn hoặc bảng chứa dòng đúng.

Khối nhỏ S — đơn vị đưa vào chỉ mục để tìm

- `row_json`: *mỗi dòng bảng một JSON* (file, page, caption, cột → giá trị).
- Với prose: câu, gộp cặp câu liền kề nếu $\cos \geq \theta = 0.9$.
- `dual_small`: xếp hạng S, trả S; `dual`: rerank rồi trả L.

Vì sao ánh xạ được như thế

1. **Gộp đoạn không gọi LLM.** Dùng quy tắc cấu trúc (bảng có hàng, có cột, có nhãn) thay cho phân loại "Có/Không" → *rẻ hơn nhiều*, tất định, tái lập được.
2. **Ranh giới khối nhỏ là một dòng bảng, không phải một câu.** Trong bảng tài chính không thể tách đơn vị bằng dấu câu — một ô là một số.
3. **Hai cấp độ có sẵn quan hệ cha–con.** Dòng → bảng; mở rộng ngữ cảnh bằng `parent` khi cần sinh.

Ý chính

Trong bảng tài chính, **đơn vị ngữ nghĩa nhỏ nhất không phải câu, mà là một dòng bảng có nhãn**. Số không tách khỏi cột mà vẫn giữ nghĩa.

Kết quả đo trên corpus tiếng Việt

Chiến lược	#chunk	R@1 chunk	MRR	R@1 page	MRR
`row_json` (chỉ dòng)	332	**81,5%**	**0,850**	**90,0%**	**0,950**
`dual_small` (chỉ S)	935	66,1%	0,723	73,9%	0,844
`dual` (rerank $S + L$, trả L)	935	50,0%	0,583	56,1%	0,751
`dual_dense` (e5-small)	935	31,5%	0,441	44,6%	0,700
`chipper` (cả bảng)	136	27,7%	0,475	36,1%	0,618

Điều đúng

`dual_small` (66,1%) vượt Chipper (27,7%) nhờ khối nhỏ là *một dòng* thay vì cả bảng.

Điều ngược kỳ vọng

Rerank bằng khối lớn làm R@1 giảm **66,1%** $\rightarrow$ **50,0%**; dense e5-small còn 31,5%. Với câu hỏi ô số, BM25 trên dòng là đủ.

Kết luận

1. Bài báo cho một câu trả lời gọn: **tách bạch đơn vị truy xuất và đơn vị sinh**.
2. Và hiện thực nó bằng cặp S (tìm) / L (sinh), với S luôn trỏ về L.
3. Cách xây L: gọi LLM hỏi Có/Không để gộp đơn vị thành đoạn văn trọn vẹn, rồi gộp đoạn dưới ngưỡng Y.
4. Cách xây S: tách câu rồi gộp cặp câu liền kề có $\cos \geq \theta$.
5. Cách dùng: xếp hạng lại bằng trung bình hai cấp, rồi có thể nhân bản khối lớn đứng đầu.
6. Kết quả: đồng bộ cải thiện trên bốn chỉ số và cả hai bộ sinh, biên độ nhỏ ($\approx 1{,}5$ ROUGE-L) nhưng lặp lại được.

Học được

Tách bạch đơn vị truy xuất và đơn vị sinh nội dung — một ý có thể dùng cho mọi miền.

Đóng góp của đồ án

Định nghĩa lại cặp đơn vị đó cho bảng tài chính không viền, bằng quy tắc cấu trúc thay vì gọi LLM.

Việc cần làm tiếp — theo thứ tự ưu tiên

1. **Giữ row-JSON làm index chính** cho câu hỏi ô số; không rerank bằng cả bảng.
2. **Đặt dual ở index riêng** (small2big) cho câu hỏi cần ngữ cảnh, rồi hợp nhất bằng RRF có trọng số thay vì trộn thô.
3. **Đo generation** trên cặp (S, L): chunk nhỏ để tìm, bảng lớn để sinh.
4. **Thử nhân bản ngữ cảnh** theo τ — chỉ có ý nghĩa khi lớp sinh đã ổn định.

Ranh giới của những gì bài báo *chưa* giải quyết

Bài báo *không* xử lý bảng, *không* nói đến đa ngôn ngữ, và *công nhận* ngưỡng τ cần chỉnh theo từng tập dữ liệu. Ba điểm này là khoảng trống hợp lệ cho phần đóng góp của đồ án.

Tài liệu tham khảo

Peng, Q., & Luo, X. (2027).
Dual-granularity chunking and dynamic context augmentation: An optimization method for retrieval-augmented generation.
Expert Systems with Applications, 332, 133546.
https://doi.org/10.1016/j.eswa.2026.133546

Gao, Y., et al. (2023).
Enhancing document understanding with a two-level RAG-like framework for retrieval-augmented generation.
Expert Systems with Applications, 261, 114963.

Arazo, E., Ortego, D., Albert, P., O'Connor, N. E., & McGuinness, K. (2020).
Pseudo-labelling and confirmation bias in deep semi-supervised learning.
In *ICNN*.

Jin, C., et al. (2025).
FlashRAG: A fast and lightweight framework for retrieval-augmented generation.